Analisis Causal de Brokers en Mercado China

Efecto causal heterogeneo (CATE) del broker sobre el retorno por caja

Fecha: 2026-04-21
Referencia: FOREVER FRESH (SHANGHAI) FRUIT
Metodologia: CausalForestDML (econml)
Outcome: RET. CAJAS (USD/caja)
Tratamiento: BROKER (discreto, multiclass o binario)

1. Resumen ejecutivo

Se estima el efecto causal de elegir un broker alternativo en lugar de FOREVER FRESH (Shanghai) sobre el retorno por caja, controlando por confounders (temporada, tipo de envase, calibre, color, etiqueta, variedad). El metodo empleado es *Double Machine Learning* con Causal Forest (econml.dml.CausalForestDML), que aisla el efecto residual del tratamiento de los controles no lineales.

Se entrenaron seis modelos para capturar distintas dimensiones de heterogeneidad: (1) modelos binarios broker-vs-referencia por semana, (2) multiclass con heterogeneidad por VARIEDAD, (3) por SERIE, (4) por ETIQUETA, (5) por CALIBRE y (6) por CODENVASE. Los resultados se consumen desde una aplicacion Streamlit que permite explorar el CATE por dimension, con filtros de significancia estadistica y de soporte empirico.

Hallazgos principales

Nuisance R^2 del modelo de Y	0.863 (estable en 3 folds)
Accuracy del modelo de T (23 brokers)	0.339 (baseline aleatorio ~0.043)
Feature importance dominante	SEMANAS_VS_CNY (49%) y RAINIER (31%)
Brokers con overlap adecuado (p_mean > 0.05)	4 de 23
Celdas filtradas por soporte (N_OBS < 10)	4.201 en variedad; 657 en serie; 1.043 en etiqueta; 3.408 en calibre; 1.36
IC_WIDTH medio (bucket N_OBS 10-50)	1.77 USD/caja (ruidoso)
IC_WIDTH medio (bucket N_OBS > 1000)	0.09 USD/caja (preciso)

2. Datos y preprocesamiento

El dataset base (df_causal) contiene embarques de cerezas a China con las siguientes columnas relevantes: BROKER, TEMPORADA, VARIEDAD COMERCIAL, CALIBRE, CODENVASE, SERIE, COLOR, ETIQUETA, SEMANAS_VS_CNY (semanas antes del Año Nuevo Chino) y RET. CAJAS (retorno en USD por caja, outcome).

Construccion de variables

Outcome Y: RET. CAJAS
Treatment T: BROKER (categorico, multiclass)
X (heterogeneidad): SEMANAS_VS_CNY + dummies de la dimension del modelo (VARIEDAD, SERIE, ETIQUETA, CALIBRE o CODENVASE)
W (confounders): dummies de las columnas restantes (TEMPORADA, CODENVASE, SERIE, COLOR)

Filtros de brokers

Solo se incluyen brokers con al menos 500 embarques y 3 temporadas, asegurando suficiente variacion temporal. Esto deja **23 brokers validos** (incluyendo la referencia FOREVER FRESH).

3. Metodologia: CausalForestDML

Double Machine Learning (DML) estima el efecto causal en dos etapas. Primero, dos modelos auxiliares (nuisance) predicen Y y T desde los controles (X, W). Segundo, se regresan los residuales de Y sobre los residuales de T para obtener un efecto "desconfundido". Este esquema elimina el sesgo de los confounders no lineales siempre que al menos uno de los dos modelos nuisance sea consistente.

El CausalForest adapta esta idea con un bosque aleatorio honesto: cada hoja aproxima el CATE(x) de una sub-region del espacio X, produciendo efectos heterogeneos con intervalos de confianza asintoticos.

Hiperparametros

model_y	RandomForestRegressor(n_estimators=100, random_state=42)
model_t	RandomForestClassifier(n_estimators=100, random_state=42)
discrete_treatment	True
n_estimators (forest)	200
cv (cross-fitting)	3
alpha (IC)	0.05 (IC 95%)

4. Modelos entrenados

Modelo	X (heterogeneidad)	Archivo PKL	CSV exportado
Broker x Semana (binarios)	SEMANAS_VS_CNY (22 modelos, 1 por broker vs rest)	modelos_brokers_semana.pkl	df_cate_brokers.csv
Broker x Variedad	SEMANAS_VS_CNY + 18 dummies de variedad	modelo_multiclass.pkl	df_cate_variedad.csv
Broker x Serie	SEMANAS_VS_CNY + 6 dummies de serie	modelo_multiclass_serie.pkl	df_cate_serie.csv
Broker x Etiqueta	SEMANAS_VS_CNY + 6 dummies de etiqueta	modelo_multiclass_etiqueta.pkl	df_cate_etiqueta.csv
Broker x Calibre	SEMANAS_VS_CNY + 21 dummies de calibre	modelo_multiclass_calibre.pkl	df_cate_calibre.csv
Broker x Codenvase	SEMANAS_VS_CNY + 6 dummies de codenvase	modelo_multiclass_codenvase.pkl	df_cate_codenvase.csv

5. Filtro de soporte empirico

Tras entrenar un modelo multiclass, se puede calcular el CATE para cualquier combinacion (broker, dimension, semana) aunque no existan observaciones reales de esa combinacion. El forest extrapola sobre los vecinos, lo que puede producir magnitudes irreales (p.ej., CATE de +187.000 USD/caja observado en la variedad SWEET HEART antes de aplicar el filtro).

Por eso, despues de generar el DataFrame de CATEs, se calcula el soporte empirico N_OBS por celda (group by broker, dimension y semana) y se enmascara con CATE = NaN toda celda con **N_OBS < 10**. Esas celdas quedan marcadas como "SIN SOPORTE" en la columna DIRECCION.

Logica aplicada (en el notebook)

```
soporte = (df_causal.groupby(['BROKER', DIM, 'SEMANAS_VS_CNY'])
.size().reset_index(name='N_OBS'))
df_cate = df_cate.merge(soporte, on=['BROKER', DIM, 'SEMANA'], how='left')
df_cate['N_OBS'] = df_cate['N_OBS'].fillna(0).astype(int)
df_cate.loc[df_cate['N_OBS'] < 10, 'DIRECCION'] = 'SIN SOPORTE'
df_cate.loc[df_cate['N_OBS'] < 10, 'CATE'] = np.nan
df_cate.to_csv('df_cate_<dim>.csv', index=False)
```

Celdas eliminadas por cada modelo

Modelo	Total celdas	Sin soporte (NaN)	Con soporte
Broker x Semana	286	27	259
Broker x Variedad	5.434	4.201	1.233
Broker x Serie	2.002	657	1.345
Broker x Etiqueta	2.002	1.043	959
Broker x Calibre	6.292	3.408	2.884
Broker x Codenvase	2.002	1.361	641

6. Diagnostico (modelo de variedad)

El bloque de diagnostico evalua cuatro aspectos del modelo entrenado sobre heterogeneidad por variedad. Los numeros corresponden al dataset completo (~270k observaciones).

6.1 Nuisance models

Metrica	Valor	Interpretacion
R^2 modelo Y (outcome)	0.863	Controles explican 86% de RET. CAJAS. Bueno pero residuales estrechos.
Accuracy modelo T (treatment)	0.339	Baseline aleatorio ~0.043. Hay confounding real, pero no violacion de positivity.

6.2 Feature importance

La heterogeneidad del CATE esta concentrada en 5 features:

Feature	Importance
SEMANAS_VS_CNY	0.4927
RAINIER	0.3084
BING	0.0756
ROYAL DAWN	0.0643
SANTINA	0.0403
Resto (14 variedades)	< 0.01 cada una

Interpretacion: para variedades como SWEET HEART, CORAL, LAPINS, BLACK PEARL, SUE, etc., el modelo no aprendio heterogeneidad real; sus CATEs son basicamente el efecto promedio condicional a la semana. Solo las 4-5 variedades dominantes muestran efectos diferenciados.

6.3 Overlap (propensity scores)

Distribucion de P(T=broker | X, W) por broker: solo 4 brokers tienen propensity media mayor a 0.05. Aproximadamente 15 brokers tienen mas del 60% de observaciones con $p < 0.01$, lo que significa que en esos contextos su efecto se estima por extrapolacion y no es confiable.

Recomendacion: para decisiones de politica globales, restringirse a los 4-5 brokers con overlap adecuado. Para decisiones locales (celda-por-celda), combinar con el filtro N_OBS por celda.

6.4 Dispersion CATE vs soporte

Bucket N_OBS	Celdas	|CATE| medio	IC_WIDTH medio
10 - 50	363	1.151	1.766
50 - 200	385	0.590	0.543
200 - 1000	378	0.348	0.227
> 1000	107	0.168	0.091

El patron es claro: a mayor soporte, menor |CATE| y IC mas estrecho. Los CATEs grandes del bucket 10-50 son predominantemente ruido, no efectos reales. Por eso la app ofrece un umbral ajustable de N_OBS en el sidebar (default 10; 50 para decisiones con alta confianza).

Grafico de diagnostico

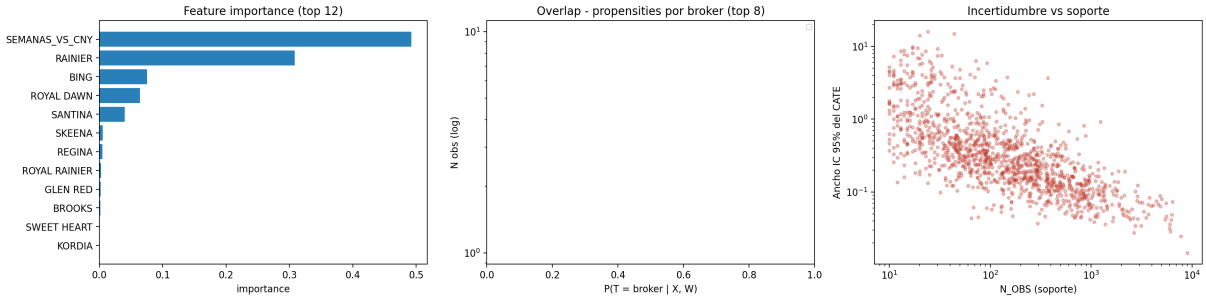

Izq: feature importance. Centro: overlap por broker. Der: incertidumbre vs soporte.

7. Aplicacion Streamlit

La app app_china_cate.py consume los CSV generados y presenta los resultados en 6 tabs:

Tab	Contenido	Fuente
1. Broker x Semana	Heatmap broker x semana (modelos binarios). Grafico de linea y barras por broker.	df_cate_brokers.csv
2. Broker x Variedad	Vistas: Por VARIEDAD, Por Broker, Consolidado. Heatmap + ranking.	df_cate_variedad.csv
3. Broker x Serie	Idem para SERIE (calibre basico).	df_cate_serie.csv
4. Broker x Etiqueta	Idem para ETIQUETA (marca).	df_cate_etiqueta.csv
5. Broker x Calibre	Idem para CALIBRE completo (21 niveles).	df_cate_calibre.csv
6. Broker x Codenvase	Idem para CODENVASE (6 envases).	df_cate_codenvase.csv

Filtros disponibles en el sidebar

Filtro	Descripcion
Ocultar valores inciertos	Oculta celdas donde el IC cruza 0 (no significativo).
Mostrar direccion (Todos / MEJOR / PEOR)	Restringe la vista a una direccion del efecto.
Registros minimos por broker (N)	Excluye brokers con menos de N embarques totales.
Temporadas minimas	Excluye brokers que no cubren al menos N temporadas.
Soporte minimo por celda (N_OBS)	Oculta celdas con soporte empirico menor al umbral. 10 = default; 50+ = solo magnitudes confiables.

Marcadores en las celdas del heatmap

Marcador	Significado
(ninguno)	Celda significativa y con soporte alto (≥ 50). Confiable.
?	Celda INCIERTA (IC cruza 0). No significativa estadisticamente.
~	Soporte bajo (10 ≤ N_OBS < 50). Direccion confiable, magnitud ruidosa.
vacio (blanco)	Filtrada por el umbral N_OBS o por el checkbox de inciertos.

8. Recomendaciones de uso

• **Usar el umbral N_OBS apropiado al tipo de decision.** 10 para exploracion (ver patrones generales), 50 para decisiones operativas (recomendar broker para un contexto concreto), 200+ para recomendaciones de alta confianza.

• **Distinguir dos tipos de confiabilidad.** El filtro de significancia (IC no cruza 0) responde "es positivo o negativo?". El filtro de soporte (N_OBS) responde "que tan precisa es la magnitud?". Ambos son complementarios.

• **Restringir recomendaciones globales a brokers con overlap alto.** Solo 4-5 brokers tienen p_mean > 0.05. Para los demas, limitarse a celdas especificas donde N_OBS sea alto.

• **Reentrenar anualmente.** Los modelos reflejan la distribucion historica. Cambios en la estructura del mercado requieren reentrenar (las celdas del notebook lo permiten sin tocar los pkl existentes).

• **Para nuevas dimensiones de analisis,** seguir el patron de las celdas EXPORT CATE <DIM> CON SOPORTE: cargar el pkl, iterar sobre (broker, dim, semana), aplicar filtro N_OBS y exportar CSV. La app detecta nuevos CSVs automaticamente si se agrega el tab correspondiente.

9. Archivos generados

Modelos entrenados (PKL):
modelos_brokers_semana.pkl, modelo_multiclass.pkl, modelo_multiclass_serie.pkl, modelo_multiclass_etiqueta.pkl, modelo_multiclass_calibre.pkl, modelo_multiclass_codenvase.pkl

CSV con filtro N_OBS aplicado:
df_cate_brokers.csv, df_cate_variedad.csv, df_cate_serie.csv, df_cate_etiqueta.csv, df_cate_calibre.csv, df_cate_codenvase.csv

App: app_china_cate.py (Streamlit)
Notebook: EDA_China (2).ipynb
Diagnostico visual: diagnostico_modelo_variedad.png